

Lista de Exercícios IPE#4b

Taiguara Melo Tupinambas

Entrega: 06 de maio de 2017

Exercício 1

O valor esperado de X_i , $E[X_i] = \frac{1}{2} - \frac{1}{2} = 0$

Logo, o valor esperado de Y_N é temos que:

$$Y_N = \sum_{i=1}^N \frac{X_i}{\sqrt{N}} \quad (1)$$

$$E[Y_N] = E\left[\sum_{i=1}^N \frac{X_i}{\sqrt{N}}\right] = \frac{1}{\sqrt{N}} NE[X] \quad (2)$$

$$E[Y_N] = 0 \quad (3)$$

A variância de X_i , $var(X_i) = E[X^2] - E^2[X] = E[X^2]$ e como $E[X^2] = \frac{1}{2} + \frac{1}{2} = 1$, temos que a variância de Y_N é dada por:

$$var(Y_N) = var\left(\frac{1}{\sqrt{N}} \sum_{i=1}^N X_i\right) = \frac{1}{N} \sum_{i=1}^N var(X_i) = var(X) \quad (4)$$

$$var(Y_N) = 1 \quad (5)$$

Logo, pelo teorema do limite central, $Y_N \sim N(0, 1)$. Realizando a simulação, os resultados encontrados foram coerentes.

```
set.seed(1)

N<-1000
n<-1000
y<-matrix(0,N)


for (i in 1:N) {
  for (j in 1:n) {
    if (runif(1)<0.5) {
      x<-1
    } else {
      x<--1
    }
    y[i]<-y[i]+x
  }
}

y<-y/sqrt(n)

cat("Média = ", mean(y), "Varância =", var(y))
```

```
## Média = -0.02340085 Varância = 1.007116
x<-seq(-4,4,length=100)
distx<-dnorm(x)

hist(y,freq = F,xlim=c(-4,4),ylim=c(0,0.5))
lines(x,distx)
```



Exercício 2

Para uma sequência de VAs independentes de Bernoulli dadas por:

$$p_X(X_i) = \begin{cases} p, & X_i = 1 \\ 1 - p, & X_i = 0 \end{cases}$$

Desta forma, o estimador de p pode ser definido como $\hat{p} = E[Y_N]$, em que $Y_N = \frac{1}{N} \sum_{i=1}^N X_i$ e a variância de Y_N é igual a $\frac{p(1-p)}{N}$.

Pela desigualdade de Chebyshev, temos que:

$$P(|\hat{Y}_N - E[Y_N]| > \epsilon) \leq \frac{\text{var}(Y_N)}{\epsilon^2} \quad (6)$$

$$P(|\hat{p} - p| > \epsilon) \leq \frac{p(1-p)}{N\epsilon^2} \quad (7)$$

A definição de um valor de N , tal que a probabilidade do valor estimado para p ser, em módulo, menor do que 0,01, de 95%, é o mesmo que dizer:

$$P(|\hat{p} - p| < 0.01) \geq 95\% \quad (8)$$

$$(9)$$

$$P(|\hat{p} - p| > 0.01) \leq 100\% - 95\% = 5\% \quad (10)$$

$$(11)$$

Ou seja, a última expressão seria a desigualdade de Chebyshev, com $\epsilon = 0.01$, e $\frac{\text{var}(Y_N)}{\epsilon^2} = \frac{p(1-p)}{0.01^2 N} = 0.05$

Logo o valor de N , que garante que a estimação de p tenha erro de no máximo 0.01, a uma probabilidade de, pelo menos, 95% é:

$$\frac{\text{var}(Y_N)}{\epsilon^2} = 0.05 \quad (12)$$

$$\frac{p(1-p)}{0.01^2 N} = 0.05 \quad (13)$$

$$N = p(1-p)2 * 10^6 \quad (14)$$

Algumas simulações foram feitas para valores de p iguais a 0.1 ($N=18000$), 0.5 ($N=50000$) e 0.75 ($N=37500$).

```
set.seed(1)

p<-c(0.1,0.5,0.75)
N<-p*(1-p)*200000
n<-100
y<-matrix(0,length(N),n)

for (k in 1:n) {
  for (i in 1:length(N)) {
    for (j in 1:N[i]) {
      if (runif(1)<p[i]) {
        x<-1
      } else {
        x<-0
      }
      y[i,k]<-y[i,k]+x
    }
    y[i,k]<-y[i,k]/N[i]
  }
}

erro<-abs(p-y)
erro<-erro<0.01

prob_erro<-matrix(0,length(N),n)

for (i in 1:length(N)) {
  prob_erro[i]<-sum(erro[i,])
}
```

```

cat("Frequência de erros menores que 0.01 para p=0.1", prob_erro[1])

## Frequência de erros menores que 0.01 para p=0.1 100
cat("\nFrequência de erros menores que 0.01 para p=0.5", prob_erro[2])

##
## Frequência de erros menores que 0.01 para p=0.5 100
cat("\nFrequência de erros menores que 0.01 para p=0.75", prob_erro[3])

##
## Frequência de erros menores que 0.01 para p=0.75 100

```

Exercício 3

Pelo teorema do limite central, a VA $Y_N = \frac{1}{N} \sum_{i=1}^N X_i$ terá uma distribuição aproximadamente normal, com média iguala $\mu = E[Y_N] = 0$ e desvio padrão igual a $\sigma = \sqrt{\text{var}(Y_N)} = \sqrt{\frac{p(1-p)}{N}}$. Sabemos, no entanto, que Para a distribuição normal, 95% dos valores estarão dentro do intervalo $\pm 1.96\sigma$. Para que, com 95% de probabilidade, o erro absoluto seja menor do que 0.01, temos que:

$$1.96\sigma = 0.01 \quad (15)$$

$$\sigma = \sqrt{\text{var}(Y_N)} = \frac{0.01}{1.96} \quad (16)$$

$$\sqrt{\frac{p(1-p)}{N}} = \frac{0.01}{1.96} \quad (17)$$

$$\frac{p(1-p)}{N} = \left(\frac{0.01}{1.96}\right)^2 \quad (18)$$

$$N = p(1-p)\left(\frac{1.96}{0.01}\right)^2 \quad (19)$$

Algumas simulações foram feitas para valores de p iguais a 0.1 (N=3458), 0.5 (N=9604) e 0.75 (N=7203).

```

set.seed(1)

p<-c(0.1,0.5,0.75)
N<-ceiling(p*(1-p)*(1.96/0.01)^2)
n<-1000
y<-matrix(0,length(N),n)

for (k in 1:n) {
  for (i in 1:length(N)) {
    for (j in 1:N[i]) {
      if (runif(1)<p[i]) {
        x<-1
      } else {
        x<-0
      }
      y[i,k]<-y[i,k]+x
    }
  }
}

```

```

        y[i,k]<-y[i,k]/N[i]
    }
}

erro<-abs(p-y)
erro<-erro<0.01

prob_erro<-matrix(0,length(N),n)

for (i in 1:length(N)) {
    prob_erro[i]<-sum(erro[i,])/length(erro[1,])
}

cat("Frequência de erros menores que 0.01 para p=0.1", prob_erro[1])

## Frequência de erros menores que 0.01 para p=0.1 0.948
cat("\nFrequência de erros menores que 0.01 para p=0.5", prob_erro[2])

##
## Frequência de erros menores que 0.01 para p=0.5 0.953
cat("\nFrequência de erros menores que 0.01 para p=0.75", prob_erro[3])

##
## Frequência de erros menores que 0.01 para p=0.75 0.949

```

Como a frequência relativa de ocorrência de erros absolutos maiores que 0.01 foi próxima do 95%, o resultado foi conforme esperado.

Interessante notar que o cálculo de N por Chebyshev é muito mais conservador do que pelo TLC.

Exercício 4

15.5

$$X_N = X_{N-1} + U_N \quad (20)$$

$$X_N = U_1 + U_2 + \dots + U_N \quad (21)$$

$$X_N = \sum_{i=1}^N U_i \quad (22)$$

$$(23)$$

Para avaliar a convergência, podemos analisar a desigualdade de Chebyshev:

$$P[|\bar{X}_N - E_X[X]| > \epsilon] \leq \frac{\text{var}(\bar{X}_N)}{\epsilon^2} \quad (24)$$

Mas, como:

$$var(\bar{X}_N) = \sum_{i=1}^N var(U_i) = \sum_{i=1}^N \frac{(1+1)^2}{12} = \sum_{i=1}^N \frac{1}{3} \quad (25)$$

$$(26)$$

$$\lim_{N \rightarrow \infty} var(\bar{X}_N) \rightarrow \infty \quad (27)$$

X_N não irá convergir.

15.6

Considerando que as variáveis X_i para $i = 1, 2, \dots, N$ são independentes e idênticamente distribuídas, temos que:

$$X_N = \frac{1}{N} \sum_{i=1}^N X_i^2 \quad (28)$$

$$E_X[X_N^2] = \frac{1}{N} \sum_{i=1}^N E_X[X^2] = E_X[X^2] \quad (29)$$

$$(30)$$

$$var(X_N^2) = E_X[X^4] - E_X^2[X^2] \quad (31)$$

Considerando que $E_X[X_N^2]$ existe, para que o estimador convirja, é necessário que $var(X_N^2) < \infty$

15.7

$$X_N = \frac{1}{\sqrt{N}} \sum_{i=1}^N X_i \quad (32)$$

$$(33)$$

$$var(X_N) = var\left(\frac{1}{\sqrt{N}} \sum_{i=1}^N X_i\right) = \frac{1}{N} var\left(\sum_{i=1}^N X_i\right) = var(X) \quad (34)$$

Como $var(X) \neq 0$, para $N \rightarrow \infty$, a variável aleatória não irá convergir

15.8

Temos que:

$$Y_N = \begin{cases} \frac{X_N}{\sqrt{N}} + 1, & \text{se } \frac{X_N}{\sqrt{N}} > 0.1 \\ \frac{X_N}{\sqrt{N}}, & \text{se } \frac{X_N}{\sqrt{N}} \leq 0.1 \end{cases}$$

Logo:

$$P[|Y_N| > \epsilon] = P[|\frac{X_N}{\sqrt{N}} + 1| > \epsilon]P[\frac{X_N}{\sqrt{N}} > 0.1] + P[|\frac{X_N}{\sqrt{N}}| > \epsilon]P[\frac{X_N}{\sqrt{N}} \leq 0.1] \quad (35)$$

$$P[|Y_N| > \epsilon] = (1 - P[-\epsilon < \frac{X_N}{\sqrt{N}} + 1 < \epsilon])P[\frac{X_N}{\sqrt{N}} > 0.1] + (1 + P[-\epsilon < \frac{X_N}{\sqrt{N}} < \epsilon])P[\frac{X_N}{\sqrt{N}} \leq 0.1] \quad (36)$$

$$(37)$$

Sabendo que:

$$\frac{X_N}{\sqrt{N}} \sim N(0, \frac{1}{\sqrt{N}}) \quad (38)$$

$$\frac{X_N}{\sqrt{N}} + 1 \sim N(1, \frac{1}{\sqrt{N}}) \quad (39)$$

Temos:

$$P[|Y_N| > \epsilon] = (1 - [Q(\frac{-\epsilon - 1}{\sqrt{\frac{1}{N}}}) - Q(\frac{\epsilon - 1}{\sqrt{\frac{1}{N}}})])Q(\frac{0.1}{\sqrt{\frac{1}{N}}}) + (1 - [Q(\frac{-\epsilon}{\sqrt{\frac{1}{N}}}) - Q(\frac{\epsilon}{\sqrt{\frac{1}{N}}})])(1 - Q(\frac{0.1}{\sqrt{\frac{1}{N}}})) \quad (40)$$

Como $\frac{1}{\sqrt{\frac{1}{N}}} = \sqrt{N}$, quando $N \rightarrow \infty$, ambos os termos tendem a 0 e, desta forma, $P[|Y_N| > \epsilon] \rightarrow 0$, C.Q.D..


```
set.seed(1)

N<-200
R<-10

y<-matrix(0,R,N)

for (j in 1:R) {
  for (i in 1:N) {
    x<-rnorm(n=1)/sqrt(i)
    if (x<0.2) {
      y[j,i]<-x
    } else {
      y[j,i]<-x+1
    }
  }
}

par(mfrow=c(2,2))
for (i in 1:4) {
  plot(c(1:N),type="l",y[i,])
  abline(h=0.2);abline(h=-0.2)
}
```




Como podemos ver, para as 4 realizações, todas convergiram para $N > 100$. No entanto, essa conclusão não pode ser generalizada para qualquer realização, conforme resultado da simulação, envolvendo 10 realizações.

O que é possível concluir é que a probabilidade de convergência é alta, para valores grandes de N .

```
plot(c(1:N),type="l",y[1,],xlab="N",ylab="Y_N",xlim=c(1, N),ylim=c(-1.5,2))
abline(h=0.2);abline(h=-0.2)

for (j in 2:R) {
  par(new=T)
  plot(y[j,],type='l',xlab="",ylab="",axes=F,xlim=c(1, N),ylim=c(-1.5,2))
}
```

Exercício 15.9

Seja $S_N = \sum_{i=1}^{100} X_i$, em que X_i é a VA resistência. De acordo com o Teorema do Limite Central, S_N tem distribuição aproximadamente normal, com $E[S_N] = NE[X] = 1000$ e $var(S_N) = Nvar(X_i) = 200$.

Desta forma, a probabilidade da resistência dos 100 resistores conectados em série ser superior a 1030 é dada por:

$$P[S_N > 1030] \approx Q\left(\frac{1030 - 1000}{\sqrt{(200)}}\right) = 0.0169 \quad (41)$$

Exercício 15.12

A PDF de Y será aproximadamente normal, com média $E[Y]$ e variância $var(Y)$.

$$E[Y] = NE[X^2] = 100(var(X) + E^2[X]) = 100.24 = 2400 \quad (42)$$

$$(43)$$

$$var(Y) = 100.var(X^2) = 100(E[X^2] - E^2[X]) \quad (44)$$

$$(45)$$

$$E[X^2] = 24 \quad (46)$$

Para encontrar $E[X^4]$, define-se $Z \sim N(0, 8)$, tal que $X = Z - 4$. Desta forma, $E[X^4] = E[(Z - 4)^4]$.

Desenvolvendo $E[(Z - 4)^4]$ e sabendo que os momentos de ordem ímpar da pdf gaussiana com média 0 é igual a 0 e que o valor esperado de uma constante é igual a própria constante, temos que:

$$E[X^4] = E[(Z - 4)^4] = E[Z^4] + 6E[Z^2](-4)^2 + (-4)^4 = 3\text{var}(Z)^2 + 96\text{var}(Z) + 256 = 1216 \quad (47)$$

Logo, $\text{var}(X^2) = 100(1216 - 576) = 640$, $\text{var}(Y) = 100\text{var}(x^2) = 6400$ e $Y \sim N(2400, 6400)$

Exercício 15.14

A PDF de Y será aproximadamente normal, com média $E[Y] = 10E[X]$ e variância $\text{var}(Y) = 10\text{var}(X)$.

$$E[X] = \int_{-\infty}^{\infty} xp(x)dx = \int_0^1 2x^2 dx = \frac{2}{3} \quad (48)$$

$$E[X^2] = \int_{-\infty}^{\infty} x^2 p(x)dx = \int_0^1 2x^3 dx = \frac{1}{2} \quad (49)$$

$$\text{var}(X) = E[X^2] - E^2[X] = \frac{1}{2} - \left(\frac{2}{3}\right)^2 = \frac{1}{18} \quad (50)$$

Logo, $Y \sim N(\frac{20}{3}, \frac{10}{18})$ e:

$$P(Y > 7) = Q\left(\frac{7 - \frac{20}{3}}{\sqrt{\frac{5}{9}}}\right) = 0.3274 \quad (51)$$

Exercício 15.17

A distribuição chi-quadrado é um caso especial da pdf gamma $\Gamma(\alpha, \beta)$, com $\alpha = \frac{v}{2}$ e $\beta = 2\sigma^2$, em que v é a quantidade de graus de liberdade (igual a N nesse caso) e σ o desvio padrão da distribuição normal que derivou a chi-quadrado que, no caso da distribuição normalizada, equivale a 1.

Ou seja, $Y_N \sim \Gamma(\frac{N}{2}, 2)$ e sua função característica é dada por:

$$\Phi_{Y_N}(w) = \frac{1}{(1 - j\omega\beta)^\alpha} \quad (52)$$

Substituindo $\alpha = \frac{N}{2}$ e $\beta = 2$, temos que:

$$\Phi_{Y_N}(w) = \frac{1}{(1 - 2j\omega)^{\frac{N}{2}}} \quad (53)$$

Definindo $Z_N = \frac{Y_N - E[Y_N]}{\sqrt{\text{var}(Y_N)}}$ e sabendo que $E[Y_N] = N$ e $\text{var}(Y_N) = 2N$, temos que

$$Z_N = \frac{Y_N - N}{\sqrt{2N}} \quad (54)$$

A função característica de Z_N é dada por:

$$\Phi_{Z_N}(w) = E[e^{j\omega Z_N}] = E_{Y_N}[e^{j\omega \frac{Y_N - N}{\sqrt{2N}}}] \quad (55)$$

$$(56)$$

Mas, separando $E_{Y_N}[e^{j\omega \frac{Y_N - N}{\sqrt{2N}}}]$ em seus dois termos, temos que:

$$E_{Y_N}[e^{j\omega \frac{Y_N - N}{\sqrt{2N}}}] = \Phi_{Y_N}(\frac{\omega}{\sqrt{2N}}) = \frac{1}{(1 - 2j\frac{\omega}{\sqrt{2N}})^{\frac{N}{2}}} \quad (57)$$

$$(58)$$

$$E_{Y_N}[e^{-j\omega \frac{N}{\sqrt{2N}}}] = e^{\frac{-j\omega N}{\sqrt{2N}}} = e^{-j\omega \sqrt{\frac{N}{2}}} = e^{-j\omega \sqrt{\frac{N}{2}}} \quad (59)$$

Logo:

$$\Phi_{Z_N} = \frac{e^{-j\omega \sqrt{\frac{N}{2}}}}{(1 - 2j\frac{\omega}{\sqrt{2N}})^{\frac{N}{2}}} \quad (60)$$

Tirando o logaritmo de ambos os lados da equação, temos que:

$$\ln \Phi_{Z_N} = -j\omega \sqrt{\frac{N}{2}} - \frac{N}{2} \ln(1 - 2j\frac{\omega}{\sqrt{2N}}) \quad (61)$$

Com $N \rightarrow \infty$ e aplicando a aproximação dada no exercício, temos:

$$\ln \Phi_{Z_N} = -j\omega \sqrt{\frac{N}{2}} - \frac{N}{2} (-2j\frac{\omega}{\sqrt{2N}} - \frac{1}{2}(2j\frac{\omega}{\sqrt{2N}})^2) \quad (62)$$

$$(63)$$

$$\ln \Phi_{Z_N} = -j\omega \sqrt{\frac{N}{2}} + j\omega \sqrt{\frac{N}{2}} + \frac{N}{4} (-\frac{2}{N}\omega^2) = -\frac{\omega^2}{2} \quad (64)$$

Logo, $\Phi_{Z_N} = e^{-\frac{\omega^2}{2}}$ e, consequentemente, $Z_N \sim N(0, 1)$, C.Q.D..

Exercício 15.24

```
N<-1000
k1<-490
k2<-510
```

```
Y<-0
```

```
for (k in k1:k2) {
```

```

    lnpy=-N*log(2)

    for (i in (N-k+1):N) {
        lnpy=lnpy+log(i)
    }

    for (i in 1:k) {
        lnpy=lnpy-log(i)
    }

    Y<-Y+exp(lnpy)
}

print(Y)

```

```
## [1] 0.49334
```

O resultado encontrado é o mesmo dado pelo livro. Se o cálculo fosse feito diretamente para cada termo, o custo computacional e a complexidade do código seria bem maior.