

Lista de Exercícios IPE#4C

Taiguara Melo Tupinambas

Entrega: 19 de junho de 2017

Exercício 1

Letra a

O estimador de máxima verossimilhança é o que maximiza a função $L(\theta|X) = \prod_{i=1}^n P(X_i|\theta)$. No caso da PMF data, temos que:

$$L(\theta|X) = \left(\frac{2\theta}{3}\right)^{N_0} \left(\frac{\theta}{3}\right)^{N_1} \left(\frac{2(1-\theta)}{3}\right)^{N_2} \left(\frac{(1-\theta)}{3}\right)^{N_3} \quad (1)$$

Em que N_i , com $i = 1, 2, 3, 4$ é a quantidade de observações repetidas.

Como a função logarítmica é monotonicamente crescente, o resultado da maximização é o mesmo, se derivarmos o logaritmo da expressão matemática.

Desta forma:

$$\log L(\theta|X) = N_0(\log(2) + \log(\theta) - \log(3)) + N_1(\log(\theta) - \log(3)) + \quad (2)$$

$$N_2(\log(2) + \log(1-\theta) - \log(3)) + N_3(\log(1-\theta) - \log(3)) \quad (3)$$

Derivando e igualando a 0, temos:

$$\frac{d\log L(\theta|X)}{d\theta} = \frac{1}{\theta}(N_0 + N_1) - \frac{1}{1-\theta}(N_2 + N_3) = 0 \quad (4)$$

Isolando θ , encontramos a seguinte expressão do estimador de máxima verossimilhança, baseado nas observações:

$$\hat{\theta} = \frac{N_0 + N_1}{N_0 + N_1 + N_2 + N_3} \quad (5)$$

Para as dez observações obtidas, o resultado pelo MV seria:

```
obs<-c(3,0,2,1,3,2,1,0,2,1)
n<-integer(4)
for (i in 0:3) {
  n[i+1]<-sum(obs==i)
}

Theta_MV<-(n[1]+n[2])/(sum(n))

cat("Theta estimado pelo MV:", Theta_MV)
```

```
## Theta estimado pelo MV: 0.5
```

O estimador do métodos dos momentos para o único parâmetro θ compara o valor esperado da VA $E[X]$ em função de θ e compara com a a média amostral. Ou seja:

$$E[X] = 0 \cdot \frac{2\theta}{3} + 1 \cdot \frac{\theta}{3} + 2 \cdot \frac{2(1-\theta)}{3} + 3 \cdot \frac{(1-\theta)}{3} \quad (6)$$

$$E[X] = \frac{7}{3} - 2\theta \quad (7)$$

$$\theta = \frac{7}{6} - \frac{E[X]}{2} \quad (8)$$

$$\hat{\theta} = \frac{7}{6} - \frac{\hat{\mu}}{2} \quad (9)$$

Para as dez observações obtidas, o resultado pelo MM seria:

```
Theta_MM<-7/6-mean(obs)/2  
  
cat("Theta estimado pelo MM:", Theta_MM)
```

```
## Theta estimado pelo MM: 0.4166667
```

Letra b

Os métodos foram aplicados para um N (quantidade de observações) crescente e o resultado da estimação de ambos é apresentada em gráficos, onde nota-se que para o aumento do tamanho da amostra os estimadores tendem a convergir.

O valor de θ escolhido para a simulação foi de 0.5.

```
set.seed(1)  
  
theta<-1/2  
N<-1000  
  
Theta_MV<-numeric(N)  
Theta_MM<-numeric(N)  
  
for (j in 1:N) {  
  x<-integer(j)  
  for (i in 1:j) {  
    r=runif(1)  
    if (r<2*theta/3) {  
      x[i]<-0  
    } else if (r<theta) {  
      x[i]<-1  
    } else if (r<theta+2*(1-theta)/3) {  
      x[i]<-2  
    } else {  
      x[i]<-3  
    }  
  }  
}  
  
# Maximum Likelihood
```

```

n<-integer(4)
for (k in 0:3) {
  n[k+1]<-sum(x==k)
}
Theta_MV[j]<-(n[1]+n[2])/(sum(n))


# Método dos Momentos
Theta_MM[j]<-(7/3-mean(x))/2
}

par(mfrow=c(2,1))


plot(Theta_MV,type="l",ylab="Theta Estimado",xlab="N",main="Máxima Verossimilhança")
abline(h=theta)
plot(Theta_MM,type="l",ylab="Theta Estimado",xlab="N",main="Método dos Momentos")
abline(h=theta)

```

Máxima Verossimilhança



Método dos Momentos



Exercício 2

O estimador de MV dado um conjunto de n observações é:

$$\log(L(\sigma|X)) = \sum_{i=1}^n \left[-\log(2) - \log(\sigma) - \frac{|x_i|}{\sigma} \right] \quad (10)$$

$$\frac{d\log(L(\sigma|X))}{d\sigma} = \sum_{i=1}^n \left[-\frac{1}{\sigma} + \frac{|x_i|}{\sigma^2} \right] = 0 \quad (11)$$

$$-\frac{n}{\sigma} + \sum_{i=1}^n \left[\frac{|x_i|}{\sigma^2} \right] = 0 \quad (12)$$

$$\hat{\sigma}_{MV} = \sum_{i=1}^n \left[\frac{|x_i|}{n} \right] \quad (13)$$

$$(14)$$

Para o estimador MM do laplaciano, é necessário calcular o segundo momento, já que $E[x] = 0 = \mu$. Dessa forma, temos que:

$$Var[X] = 2\sigma^2 = E[X^2] - E[X]^2 = E[X^2] = 2\sigma^2 \quad (15)$$

Logo, para estimar σ com o MM a partir de um conjunto de n observações:

$$\hat{E}[X^2] = \sum_n \frac{|x_i|^2}{n} = 2\hat{\sigma}^2 \quad (16)$$

$$(17)$$

$$\hat{\sigma} = \sqrt{\frac{\sum |x_i|^2}{2N}} \quad (18)$$

Para avaliar a convergência via simulação, foi definido um valor de $\sigma = 2$ e foram geradas observações utilizando a CDF inversa do laplaciano, dada por:

$$F^{-1}(x) = \mu - \sigma \operatorname{sgn}(x - 0.5) \ln(1 - 2|x - 0.5|) \quad (19)$$

Em que $\mu = 0$.

Mais uma vez, nota-se que para o aumento do tamanho da amostra os estimadores tendem a convergir.

```
set.seed(1)

sigma<-1
N<-1000

sigma_MV<-numeric(N)
sigma_MM<-numeric(N)

for (j in 1:N) {
  u <- runif(j)
  x <- -sigma*sign(u-0.5)*log(1-2*abs(u-0.5))
```

```

# Máxima Verossimilhança
sigma_MV[j]<-sum(abs(x))/j


# Método dos Momentos
sigma_MM[j]<-sqrt(sum(abs(x)^2)/(2*j))
}

par(mfrow=c(2,1))


plot(sigma_MV,type="l",ylab="Sigma Estimado",xlab="N",main="Máxima Verossimilhança")
abline(h=sigma)
plot(sigma_MM,type="l",ylab="Sigma Estimado",xlab="N",main="Método dos Momentos")
abline(h=sigma)

```

Máxima Verossimilhança



Método dos Momentos



Exercício 3

O estimador de MV de $\theta = (\mu, \sigma)$ dado um conjunto de n observações é dado por:

$$\log(L(\theta|X)) = \sum_{i=1}^n \left[-\log\sigma - \frac{1}{2}\log 2\pi - \frac{1}{2\sigma^2}(x_i - \mu)^2 \right] \quad (20)$$

$$\log(L(\theta|X)) = -n\log\sigma - \frac{n}{2}\log 2\pi - \frac{1}{2\sigma^2} \sum_n (x_i - \mu)^2 \quad (21)$$

$$(22)$$

$$\frac{\delta \log(L(\theta|X))}{\delta \mu} = -\frac{1}{\sigma^2} \sum_n (x_i - \mu) = 0 \quad (23)$$

$$\frac{\delta \log(L(\theta|X))}{\delta \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_n (x_i - \mu)^2 = 0 \quad (24)$$

$$(25)$$

Desta forma, resolvendo o sistema, temos que:

$$\hat{\mu}_{MV} = \bar{x} \quad (26)$$

$$\hat{\sigma}_{MV} = \sqrt{\frac{1}{n} \sum_n (x_i - \bar{x})^2} \quad (27)$$

Desenvolvendo o somatório temos que:

$$\frac{1}{n} \sum_n (x_i - \bar{x})^2 = \frac{1}{n} \sum_n (x_i^2 - 2x_i\bar{x} + \bar{x}^2) = \frac{1}{n} \sum_n x_i^2 - 2\bar{x} \frac{1}{n} \sum_n x_i + \bar{x}^2 \quad (28)$$

$$= \frac{1}{n} \sum_n x_i^2 - 2\bar{x}^2 + \bar{x}^2 = \frac{1}{n} \sum_n x_i^2 - \bar{x}^2 \quad (29)$$

Logo:

$$\hat{\mu}_{MV} = \bar{x} \quad (30)$$

$$\hat{\sigma}_{MV} = \sqrt{\frac{1}{n} \sum_n x_i^2 - \bar{x}^2} \quad (31)$$

O estimador pelo MM de $\theta = (\mu, \sigma)$ dado um conjunto de n observações é dado por:

$$E[X] = \mu \quad (32)$$

$$\hat{\mu}_{MM} = \bar{x} \quad (33)$$

$$(34)$$

$$E[X^2] = Var[X] + \mu^2 = \sigma^2 + \mu^2 \quad (35)$$

$$\sigma^2 = E[X^2] - \mu^2 \quad (36)$$

$$\hat{\sigma}_{MM} = \sqrt{\frac{1}{n} \sum_n x_i^2 - \bar{x}^2} \quad (37)$$

Desta forma, temos que $\theta_{MV} = \theta_{MM}$, c.q.d.

Para estimar via simulação foi considerado um $\theta = (\mu = 1, \sigma = 3)$ e o resultado obtido mostra que os estimadores parece convergir a medida que o tamanho amostral aumenta.

```
set.seed(1)

mu<-1
sigma<-3
N<-1000

mu_est<-numeric(N)
sigma_est<-numeric(N)

for (j in 1:N) {
  x <- rnorm(j,mean=mu,sd=sigma)

  # Máxima Verossimilhança
  mu_est[j]<-sum(x)/j

  # Método dos Momentos
  sigma_est[j]<-sqrt(1/j*sum(x^2)-mu_est[j])
}

par(mfrow=c(2,1))

plot(mu_est,type="l",ylab="Média Estimada",xlab="N")
abline(h=mu)
plot(sigma_est,type="l",ylab="Sigma Estimado",xlab="N")
abline(h=sigma)
```

