

# Lista de Exercícios IPE#6

*Taiguara Melo Tupinambas*

*Entrega: 12 de julho de 2017*

## Capítulo 21 - Poisson

### Exercício 21.1

$$P_k(t) = P[N(t) = k] \quad (1)$$

Como as únicas possibilidades se ter  $k$  chegadas até o tempo  $t$  são:

- $k$  chegadas no intervalo  $[0, t - \Delta t]$  e nenhuma no intervalo  $(t - \Delta t, t]$ ;
- $k - 1$  chegadas no intervalo  $[0, t - \Delta t]$  e uma chegada no intervalo  $(t - \Delta t, t]$ ;

Temos que:

$$P[N(t) = k] = P[N(t - \Delta t) = k - 1, N(t) - N(t - \Delta t) = 1] + P[N(t - \Delta t) = k, N(t) - N(t - \Delta t) = 0] \quad (2)$$

Por independência (3) e estacionariedade (4) dos incrementos:

$$P[N(t) = k] = P[N(t - \Delta t) = k - 1]P[N(t) - N(t - \Delta t) = 1] + P[N(t - \Delta t) = k]P[N(t) - N(t - \Delta t) = 0] \quad (3)$$

$$P[N(t) = k] = P[N(t - \Delta t) = k - 1]P[N(t + \Delta t) - N(t) = 1] + P[N(t - \Delta t) = k]P[N(t + \Delta t) - N(t) = 0] \quad (4)$$

Substituindo:

- $P[N(t - \Delta t) = k - 1] = P_{k-1}(t - \Delta t)$ ;
- $P[N(t - \Delta t) = k] = P_k(t - \Delta t)$ ;
- $P[N(t + \Delta t) - N(t) = 1] = \lambda \Delta t$ ;
- $P[N(t + \Delta t) - N(t) = 0] = 1 - \lambda \Delta t$ .

Temos que:

$$P_k(t) = P_{k-1}(t - \Delta t)\lambda \Delta t + P_k(t - \Delta t)(1 - \lambda \Delta t) \quad (5)$$

$$P_k(t) - P_k(t - \Delta t) = P_{k-1}(t - \Delta t)\lambda \Delta t - P_k(t - \Delta t)\lambda \Delta t \quad (6)$$

$$\frac{P_k(t) - P_k(t - \Delta t)}{\Delta t} = P_{k-1}(t - \Delta t)\lambda - P_k(t - \Delta t)\lambda \quad (7)$$

Com  $\Delta t \rightarrow 0$ :

$$\frac{dP_k(t)}{dt} = P_{k-1}(t)\lambda - P_k(t)\lambda \quad (8)$$

$$\frac{dP_k(t)}{dt} + P_k(t)\lambda = P_{k-1}(t)\lambda \quad (9)$$

C.Q.D.

## Exercício 21.2

Fazendo a transformada de Laplace da Eq. 21.3:

$$sP_k(s) - P_k(0^+) + \lambda P_k(s) = \lambda P_{k-1}(s) \quad (10)$$

Mas,  $P_k(0^+) = P[N(0^+) = k] = N(0)$

Como  $N(0) = 0$ :

$$sP_k(s) + \lambda P_k(s) = \lambda P_{k-1}(s) \quad (11)$$

$$P_k(s) = \frac{\lambda}{\lambda + s} P_{k-1}(s) \quad (12)$$

Resolvendo recursivamente, temos que:

$$P_k(s) = \left( \frac{\lambda}{\lambda + s} \right)^k P_0(s) \quad (13)$$

Resolvendo para  $P_0(s)$ :

$$P_0(s) = L\{P_0(t)\} = L\{e^{\lambda t} u(t)\} = \frac{1}{s + \lambda} \quad (14)$$

Logo:

$$P_k(s) = \frac{\lambda^k}{(\lambda + s)^{k+1}} \quad (15)$$

E, pela tabela de transformadas:

$$P_k(t) = e^{-\lambda t} \frac{(\lambda t)^k}{k!} \quad (16)$$

para  $k=0,1,2,\dots$

## Exercício 21.6

A probabilidade de haver mais de 12 ligações no primeiro minuto é:

$$P[N(60) > 12] = 1 - P[N(60) \leq 12] \quad (17)$$

$$P[N(60) > 12] = 1 - \sum_{k=0}^{12} e^{-\lambda t} \frac{(\lambda t)^k}{k!} \quad (18)$$

Para  $\lambda = \frac{1}{5}$  e  $t = 60$ :

$$P[N(60) > 12] = 1 - e^{-12} \sum_{k=0}^{12} \frac{12^k}{k!} \quad (19)$$

```
x<-0;
for (i in 0:12) {
  x<-x+(12^i)/factorial(i)
}

Ans<-1-exp(-12)*x

cat("Resposta:", Ans)
```

## Resposta: 0.4240348

## Exercício 21.8

$$P[T > t] = P[\min(T_1^{(1)}, T_1^{(2)})] = P[T_1^{(1)} > t, T_1^{(2)} > t] \quad (20)$$

Por independência:

$$P[T > t] = P[T_1^{(1)} > t] P[T_1^{(2)} > t] = P^2[T_1 > t] \quad (21)$$

$$(22)$$

$$P[T > t] = \left( \int_t^\infty \lambda e^{-\lambda x} dx \right)^2 = e^{-2\lambda t} \quad (23)$$

Mas,  $P[T > t] = 1 - F_T(t)$ , logo:

$$p_T(t) = \frac{d(1 - e^{-2\lambda t})}{dt} = 2\lambda e^{-2\lambda t} \quad (24)$$

### Exercício 21.9

Seja  $N_s(t) = N_1(t) + N_2(t)$ , com  $N_s(0) = N_1(0) + N_2(0) = 0$ .

Os incrementos de  $t_4 > t_3$  e  $t_2 > t_1$  são dados por:

$$N_s(t_2) - N_s(t_1) = (N_1(t_2) - N_1(t_1)) + (N_2(t_2) - N_2(t_1)) \quad (25)$$

$$N_s(t_4) - N_s(t_3) = (N_1(t_4) - N_1(t_3)) + (N_2(t_4) - N_2(t_3)) \quad (26)$$

Se  $N_1(t)$  e  $N_2(t)$  são processos de *Poisson* independentes, então cada termo das equações acima também são independentes entre si e a soma da primeira equação é independente da soma da segunda equação (os incrementos de  $N_s$  são estacionários).

Utilizando a função característica de  $N_s$ , temos:

$$\Phi_{N_s}(\omega) = \Phi_{N_1}(\omega)\Phi_{N_2}(\omega) \quad (27)$$

$$\Phi_{N_s}(\omega) = e^{\lambda_1 t(e^{j\omega} - 1)} e^{\lambda_2 t(e^{j\omega} - 1)} = e^{(\lambda_1 + \lambda_2)t(e^{j\omega} - 1)} \quad (28)$$

Logo,  $N_s(t) \sim \text{Pois}((\lambda_1 + \lambda_2)t)$

### Exercício 21.10

Valor esperado:

$$E[N(t_2) - N(t_1)] = \lambda t_2 - \lambda t_1 = \lambda(t_2 - t_1) \quad (29)$$

Para variância, utiliza-se do fato de que os incrementos são estacionários e a tabela de VAs para Poisson:

$$\text{var}(N(t_2) - N(t_1)) = \text{var}(N(t_2 - t_1)) = \lambda(t_2 - t_1) \quad (30)$$

### Exercício 21.16

Temos que  $P[t - \Delta t \leq T_k \leq t]$  é igual a  $P[(k-1)$  chegadas em  $[0, t - \Delta t] \cup$  uma chegada em  $(t - \Delta t, t]$ .

Logo:

$$P[t - \Delta t \leq T_k \leq t] = e^{-\lambda(t - \Delta t)} \frac{(\lambda(t - \Delta t))^{k-1}}{(k-1)!} \lambda \Delta t \quad (31)$$

$$\frac{P[t - \Delta t \leq T_k \leq t]}{\Delta t} = e^{-\lambda(t - \Delta t)} \frac{(\lambda(t - \Delta t))^{k-1}}{(k-1)!} \lambda \quad (32)$$

Com  $\Delta t \rightarrow 0$ :

$$\lim_{\Delta t \rightarrow 0} \frac{P[t - \Delta t \leq T_k \leq t]}{\Delta t} = e^{-\lambda t} \frac{(\lambda t)^{k-1}}{(k-1)!} \lambda = \frac{\lambda^k}{(k-1)!} t^{k-1} e^{-\lambda t} \quad (33)$$

## Capítulo 22 - Markov

### Exercício 22.15

Os estados são:  $[0, 1, 2, 3]$  e suas transições:

- $P_{00} = 1, P_{01} = 0, P_{02} = 0, P_{03} = 0$
- $P_{10} = \frac{1}{2}, P_{11} = \frac{1}{2}, P_{12} = 0, P_{13} = 0$
- $P_{20} = \frac{1}{4}, P_{21} = \frac{1}{2}, P_{22} = \frac{1}{4}, P_{23} = 0$
- $P_{30} = \frac{1}{8}, P_{31} = \frac{3}{8}, P_{32} = \frac{3}{8}, P_{33} = \frac{1}{8}$

Temos, então, a matriz de transição da seguinte forma:

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 & 0 \\ \frac{1}{4} & \frac{1}{2} & \frac{1}{4} & 0 \\ \frac{1}{8} & \frac{3}{8} & \frac{3}{8} & \frac{1}{8} \end{bmatrix}$$

```
P<-matrix(c(1,0,0,0,
            1/2,1/2,0,0,
            1/4,1/2,1/4,0,
            1/8,3/8,3/8,1/8),
          nrow=4,ncol=4,byrow=TRUE)
```

```
for (i in 1:15) {
  P<-P%*%P
}
```

```
cat("P infinito:\n")
```

```
## P infinito:
```

```
print(P)
```

```
##      [,1] [,2] [,3] [,4]
## [1,]    1    0    0    0
## [2,]    1    0    0    0
## [3,]    1    0    0    0
## [4,]    1    0    0    0
```

Para qualquer que seja o  $\pi_0$ , as probabilidades estacionárias serão:  $\pi = [1, 0, 0, 0]^T$ . Ou seja, a probabilidade de todas as lâmpadas falharem (estado 0) chega a 100%.

### Exercício 22.17

Pelo teorema de *Perron-Frobenius*, sabe-se que a matriz  $P^n$  tem um autovalor  $\lambda_1 = 1$  e os outros autovalores com módulo menor do que 1.

Dessa forma, considerando  $\mathbf{P}^n = \mathbf{V} \mathbf{\Lambda}^n \mathbf{V}^{-1}$ , em que  $\mathbf{V} = [\mathbf{v}_1 \ \mathbf{v}_2 \ \mathbf{v}_3]$  e  $\mathbf{V}^{-1} = [\mathbf{w}_1 \ \mathbf{w}_2 \ \mathbf{w}_3]$ , teremos que  $\mathbf{P}^n \rightarrow \mathbf{v}_1 \mathbf{w}_1^T$ .

Como  $\mathbf{P}^\infty \mathbf{1} = \mathbf{1}$ , logo:  $\mathbf{v}_1 \mathbf{w}_1^T \mathbf{1} = \mathbf{1}$ .

Mas,  $\mathbf{w}_1^T \mathbf{1}$  é um escalar ( $k$ ). Fazendo  $k = \frac{1}{c}$ , temos que:  $\mathbf{v}_1 \mathbf{w}_1^T \mathbf{1} = \mathbf{v}_1 \frac{1}{c} = \mathbf{1} \rightarrow \mathbf{v}_1 = c \mathbf{1}$ .

Sabemos, também, que  $\pi^T \mathbf{v}_1 \mathbf{w}_1^T = \pi^T$  e que  $\pi^T \mathbf{v}_1$  também é um escalar ( $k$ ). Fazendo  $k = \frac{1}{d}$ , temos que  $\pi^T \mathbf{v}_1 \mathbf{w}_1^T = \frac{1}{d} \mathbf{w}_1^T = \pi^T \rightarrow \mathbf{w}_1 = d \pi^T$ .

Logo, sabendo que  $\pi^T \mathbf{1} = 1$ :

$$\mathbf{w}_1^T \mathbf{v}_1 = (d\pi)^T \mathbf{c} \mathbf{1} = 1 \quad (34)$$

$$\pi^T \mathbf{1} c d = 1 \quad (35)$$

$$c d = 1 \quad (36)$$

$$\mathbf{P}^\infty = \mathbf{1} \pi^T \quad (37)$$

C.Q.D.

## Exercício 22.18

```
P<-matrix(c(0.1,0.4,0.5,
            0.2,0.5,0.3,
            0.3,0.3,0.4),
          nrow=3,ncol=3,byrow=TRUE)
```

```
for (i in 1:100) {
  P<-P%*%P
  P<-round(P,digits=4)
}
```

```
cat("P^100:\n")
```

```
## P^100:
```

```
print(P)
```

```
##      [,1] [,2] [,3]
## [1,] 0.2165 0.4021 0.3814
## [2,] 0.2165 0.4021 0.3814
## [3,] 0.2165 0.4021 0.3814
```

O resultado está de acordo com a teoria, uma vez que as linhas continuam somando para 1, e, com  $n \rightarrow \infty$ , as linhas de  $P^n$  serão iguais.

## Exercício 22.24

```
P<-matrix(c(6/8,1/8,1/8,
            5/8,2/8,1/8,
            4/8,3/8,1/8),
          nrow=3,ncol=3,byrow=TRUE)
```

```
for (i in 1:100) {
  P<-P%*%P
  P<-round(P,digits=4)
}
```

```
cat("P^100:\n")
```

```
## P^100:
```

```
print(P)
```

```
##      [,1] [,2] [,3]
## [1,] 0.6964 0.1786 0.125
## [2,] 0.6964 0.1786 0.125
## [3,] 0.6964 0.1786 0.125
```

No caso do Exemplo 22.8, a matriz de transição era do tipo *doubly stochastic matrix*, já que, além das linhas somarem 1, as colunas também, o que resulta em probabilidades estacionárias iguais. Nesse caso, temos como probabilidade estacionária:  $\pi = [0.6964 \ 0.1786 \ 0.1250]^T$

## Exercício 22.26

Para montar a Matrix de Transição, foi feito um código em R, considerando que a primeira linha (dia 0) é igual a  $[1 \ 0 \ 0 \ 0 \ 0]$ .

Para os outros dias, foi considerada uma PMF binomial, com  $P[n] = \binom{k}{n} \left(\frac{1}{2}\right)^n \left(1 - \frac{1}{2}\right)^{k-n}$

```
p<-1/2
P<-matrix(0,5,5)
P[1,]<-c(1,0,0,0,0)

for (k in 1:4) {
  for (n in 0:k) {
    P[k+1,n+1]<-ncol(combn(k,n))*p^n*(1-p)^(k-n)
  }
}

cat("P:\n")
```

```
## P:
```

```
print(P)
```

```
##      [,1] [,2] [,3] [,4] [,5]
## [1,] 1.0000 0.000 0.000 0.000 0.0000
## [2,] 0.5000 0.500 0.000 0.000 0.0000
## [3,] 0.2500 0.500 0.250 0.000 0.0000
## [4,] 0.1250 0.375 0.375 0.125 0.0000
## [5,] 0.0625 0.250 0.375 0.250 0.0625
```

Considerando que os estados são as quantidades de peixes ( $k=0,1,2,3,4$ ) presentes no poço, deseja-se encontrar quando o estado 0 terá mais do que 90% de probabilidade.

Dessa forma:

```
pi<-c(0,0,0,0,1)
n<-0
while (pi[1]<0.9) {
  pi<-pi%*%P
  n<-n+1
}

cat("0 pescador deve planejar pescar por",n,
    "dias")
```

## 0 pescador deve planejar pescar por 6 dias

### Exercício 22.27

Temos que  $\mathbf{P}^T \mathbf{1} = \mathbf{1}$ . Logo:

$$\mathbf{P}^T(\mathbf{P}^T \mathbf{1}) = \mathbf{P}^{T^2} \mathbf{1} \quad (38)$$

$$\mathbf{P}^T(\mathbf{P}^T \mathbf{1}) = \mathbf{P}^T \mathbf{1} \quad (39)$$

$$\mathbf{P}^{T^2} = \mathbf{P}^T \quad (40)$$

$$\mathbf{P}^{\infty T} \mathbf{1} = \mathbf{1} \quad (41)$$

Pelo problema 22.17, temos que :  $\mathbf{P}^\infty = \mathbf{1}\pi^T$ . Logo:

$$\mathbf{P}^\infty \mathbf{1} = (\mathbf{1}\pi^T)^T \mathbf{1} = \mathbf{1} \quad (42)$$

$$\pi \mathbf{1}^T \mathbf{1} = \mathbf{1} \quad (43)$$

$$(44)$$

Mas, como  $\mathbf{1}^t \mathbf{1} = \mathbf{k}$  sendo k um escalar constante, temos que:  $\pi = \frac{1}{\mathbf{k}}$ , como queríamos demonstrar.